

UNIVERSIDADE PRESBITERIANA MACKENZIE
FACULDADE DE COMPUTAÇÃO E INFORMÁTICA
TECNOLOGIA EM CIÊNCIAS DE DADOS

PROJETO APLICADO II

PROFESSOR:

Felipe Albino dos Santos

GRUPO:

Daniel Fernandes Saraiva – 10381985 - 10381985@mackenzista.com.br

David Wildson Gonçalves Santos – 10744094 – 10744094@mackenzista.com.br

Vinicius Neves Tavares Alves – 10731681 - 10731681@mackenzista.com.br

São Paulo

2026

Sumário

1. Contexto do Estudo.....	3
a. Nome das empresas.....	3
b. Apresentação da Empresa e Área de Atuação.....	3
c. Premissas do Projeto.....	4
d. Objetivos.....	4
e. Metas.....	4
f. Cronograma de Atividades.....	4
2. Metodologia do projeto.....	5
a. Definição da Linguagem de programação.....	5
b. Análise exploratória da base de dados.....	5
c. Tratamento da base de dados.....	10
d. Definição e descrição das bases teóricas dos métodos.....	11
e. Definição e descrição de como será calculada a acurácia.....	11
3. Descrição dos Resultados e Modelo de	
Negócios.....	11
a. Definição do Produto.....	12
b. Modelo de Negócios.....	12
4. Link GitHub.....	12

1. Contexto do Estudo

a. Nome das empresas

Mercado Livre, Amazon, Magalu, Shopee e Americanas.

b. Apresentação da Empresa e Área de Atuação

Mercado Livre: Fundada em 1999, é a empresa líder em tecnologia para e-commerce e serviços financeiros na América Latina. Opera um ecossistema completo que busca democratizar o comércio e o dinheiro na região.

Área de Atuação: Atua como um Marketplace multicanal e provedor de soluções logísticas (Mercado Envios). Seu ecossistema inclui o Mercado Pago (fintech), Mercado Ads (publicidade) e Mercado Shops. Em 2026, consolidou-se também no setor B2B e vendas para o governo.

Amazon Brasil: Braço brasileiro da gigante global de tecnologia, a Amazon foca na "obsessão pelo cliente". É reconhecida por sua infraestrutura logística avançada e pelo programa de fidelidade Amazon Prime.

Área de Atuação: Foca em Venda Direta (1P) e Marketplace (3P), abrangendo desde eletrônicos até bens de consumo rápido. Além do varejo, atua fortemente em Serviços de Nuvem (AWS) e Streaming/Conteúdo Digital, utilizando Inteligência Artificial para otimizar a experiência de compra.

Magazine Luiza: Uma das maiores varejistas do Brasil, o Magalu completou uma transformação digital histórica, deixando de ser uma loja tradicional que vende online para se tornar uma "plataforma digital de vendas com pontos físicos".

Área de Atuação: Opera no modelo Ominichannel (integração loja física e digital). Sua atuação se expandiu para além do varejo através do "Magalu Cloud" (tecnologia), Magalog (logística para terceiros) e serviços financeiros (MagaluPay), focando na digitalização do varejo brasileiro.

Shopee: Lançada em 2015 em Cingapura e operando no Brasil desde 2019, a Shopee rapidamente se tornou uma das plataformas favoritas dos brasileiros devido à sua estratégia de "Social Commerce" e gamificação.

Área de Atuação: Atua como um Marketplace puro, conectando vendedores (majoritariamente PME - Pequenas e Médias Empresas) a consumidores. Em 2026, foca intensamente na capacitação de vendedores locais e na expansão de sua malha logística própria com novos Centros de Distribuição no Brasil.

Americanas: Uma marca centenária e icônica no varejo brasileiro, a Americanas S.A. passa por um processo de reestruturação focado em eficiência operacional e manutenção da confiança do consumidor após seu plano de recuperação judicial.

Área de Atuação: Especializada em Varejo Híbrido, utilizando sua capilaridade de lojas físicas como "dark stores" para entregas rápidas. Atua fortemente em datas sazonais e no setor de Retail Media, integrando anúncios digitais com a experiência de compra física.

c. Premissas do Projeto

Desenvolvimento de um estudo prático sobre análise comparativa de eficiência no atendimento ao consumidor.

d. Objetivos

- Identificar padrões setoriais: Verificar se as reclamações são sazonais ou se estão ligadas a falhas estruturais de modelos de negócio específicos.
- Benchmarking de Desempenho: Comparar as “Big Five” do varejo brasileiro para estabelecer qual delas possui o banco de dados de atendimento mais otimizado para a satisfação do cliente.
- Análise de causa raiz e reincidência: Investigar os motivos predominantes das reclamações para identificar se são falhas pontuais ou problemas sistêmicos recorrentes.
- Avaliação do índice de eficácia na recuperação de clientes: O objetivo é cruzar o status da reclamação (Resolvida vs. Não Resolvida) com o sentimento final do consumidor, quantificando o impacto que um atendimento eficiente tem na manutenção da reputação da marca e na fidelização do usuário dentro do ecossistema de e-commerce.

e. Metas

- Criar séries históricas que indiquem a evolução das reclamações por período (Ano, Mês, Ano/Mês).
- Mapear a distribuição geográfica das manifestações por UF e município.
- Elaborar dashboards ou relatórios visuais que apresentem a situação por serviço e por marca.
- Identificar o ranking de problemas mais frequentes relatados pelos consumidores.
- Calcular indicadores comparativos, como quantidade de reclamações por serviço e por empresa.
- Propor recomendações baseadas em evidências para melhorar a transparência, a regulação e o atendimento ao consumidor.

f. Cronograma de Atividades

	MARÇO				ABRIL					MAIO					
	S2	S3	S4	S5	S1	S2	S3	S4	S5	S1	S2	S3	S4	S5	
Etapa I															
FORMAÇÃO DE GRUPOS															TODOS
PREMISSAS DO PROJETO															TODOS
OBJETIVOS E METAS															TODOS
CRONOGRAMA DE ATIVIDADES															TODOS
Etapa II															
ANÁLISE EXPLORATÓRIA DA BASE DE DADOS															VINICIUS
DEFINIÇÃO MÉTODO ANALÍTICO															TODOS
ATUALIZAÇÃO DO DOCUMENTO															DAVID
AJUSTES DE OBJETIVOS E CRONOGRAMAS															TODOS
Etapa III															
CONSOLIDAÇÃO DOS RESULTADOS															VINICIUS
DESCRIÇÃO DOS RESULTADOS															DAVID
RASCUNHO DE MODELO DE NEGÓCIOS															TODOS
ESBOÇO DO STORYTELLING															DANIEL
Etapa III															
APRESENTAÇÃO DO DATA STORYTELLING															TODOS
DOCUMENTO FINAL ATUALIZADO															TODOS
LINK REPOSITÓRIO GITHUB E SCRIPTS															TODOS
GRAVAÇÃO DA APRESENTAÇÃO															TODOS

 Tarefas Realizadas
 Tarefas a Realizar

2. Metodologia no projeto


a. Definição da Linguagem de programação

Estamos utilizando a linguagem de programação Python por ter uma vasta biblioteca de Ciência de Dados e facilidade na manipulação de grandes volumes de dados. Estamos utilizando principalmente a biblioteca Pandas para manipulação de dados, *Seaborn/Matplotlib* para visualização estatística, *Scikit-Learn* para implementação do modelo *Random Forest* e OS portabilidade.

b. Análise exploratória da base de dados

- Volume de Reclamações por Empresa

1. Volume de Reclamações por Empresa




Este gráfico de barras horizontais apresenta a contagem total de reclamações registradas na base de dados com o nome de cada empresa analisada. O Mercado Livre lidera isoladamente com o maior volume de reclamações, aproximando-se da marca de 6.000 registros.

Amazon e Shopee Brasil ocupam o segundo e terceiro lugar, respectivamente, com volumes situados entre 2.500 e 3.100 registros. Já o Magazine Luiza aparece com reclamações divididas entre loja Online e Física, sendo a primeira com volume significativamente maior em comparação à segunda que teve mais que 2.000 registros.

As marcas do grupo Americanas e serviços como ShopeePay, apresentaram os menores volumes relativos nesta base.

Notamos ainda que, o alto volume do Mercado Livre não indica necessariamente uma qualidade abaixo dos demais concorrentes, mas reflete sua posição como líder de mercado na América Latina. Para o modelo preditivo que desenvolveremos, esses dados indicam a necessidade de normalização, garantindo que o modelo não seja tendencioso apenas para a empresa com maior número de amostras.

- **Ranking de Problemas Mais Frequentes**



O gráfico apresenta os cinco tipos de problemas com maior incidência na base de dados, consolidando os registros de todas as empresas analisadas. As frequências absolutas estão indicadas ao final de cada barra.


Notamos que logística e entrega lidera com o maior volume de dados, confirmando que a eficiência na logística continua sendo o maior desafio para o varejo digital. Já as transações financeiras ocupam o segundo lugar com o volume quase idêntico ao da entrega, o que demonstra possível falha no processo de logística reversa e estorno.

Quando o assunto é na parte de vendas e ofertas, notamos que o volume foi de 1.634 registros, o que pode indicar um problema na comunicação e marketing ou até estoque real de produtos.

Os dois últimos maiores registros estão voltados para a qualidade do produto e integridade, o que pode indicar falha no manuseio ou conferência do item, antes de chegar ao cliente final.

A proximidade estatística entre os problemas de entrega e reembolso sugere que o consumidor está enfrentando uma dupla falha, ele não recebe o produto no prazo anunciado e encontra barreiras para recuperar o dinheiro investido.

- **Análise comparativa por Empresa**



No gráfico acima segmentamos os cinco principais problemas distribuídos entre as empresas analisadas. O Mercado Livre demonstrou um volume acentuado em Dificuldade/atraso na devolução de valores e não entrega, como o ML atua fortemente com o modelo de *Marketplace* e sua própria *fintech* (Mercado Pago), a retenção de valores aparece como um ponto crítico de atrito.


Já no caso da Amazon o destaque negativo recai sobre a não entrega e demora na entrega. Mesmo sendo conhecida por ter uma logística global eficiente, o volume de reclamações no Brasil sugere desafios na malha logística ou com suas transportadoras parceiras.

Shopee Brasil demonstra um perfil mais equilibrado entre os problemas, mas com relevância no item dificuldade na devolução de valores, o que reflete os desafios em processar os reembolsos em uma plataforma com milhares de pequenos vendedores.

Magazine Luiza na parte online segue o padrão setorial com foco em atraso na entrega, porém com o volume de produto danificado proporcionalmente relevante, o que pode indicar gargalos no manuseio de categorias específicas. Já a loja física, conforme esperado, apresenta volumes mínimos, servindo como base de controle para mostrar que o atrito está concentrado na experiência digital e não no atendimento presencial.

- **Distribuição Geográfica das Reclamações – Nacional**

2. Distribuição por Região




Para compreender o alcance nacional do que está sendo analisado e identificar onde os gargalos de atendimento são mais críticos, analisamos a volumetria pelas cinco regiões do Brasil. A visualização do gráfico permite identificar a concentração de demanda e possíveis desigualdades na infraestrutura de atendimento e logística regional.

Região sudeste detém a maioria absoluta das manifestações com mais de 53%, o que reflete a densidade populacional e a concentração do polo econômico e logístico do *e-commerce* brasileiro. Já a região nordeste aparece como a segunda região com mais registros (19,7%), demonstrando o crescimento do consumo digital e a importância estratégica dessa malha para as gigantes do setor.

Região sul contribuiu com pouco mais de 15% das reclamações, mantendo uma proporção condizente com seu volume de mercado. Sendo que, as regiões centro-oeste

e norte, apresentaram os menos índices, com algo na casa dos 8,3% e 3,3%, respectivamente.

- **Volume de Reclamações por Empresa e Região**



Mercado Livre e Amazon apresentam um perfil de “escada” regional muito similar, ocupando mais de 50% do volume total da região sudeste, confirmando que a disputa pela liderança do e-commerce brasileiro está concentrada no eixo sul-sudeste. Shopee Brasil embora siga o padrão nacional, apresenta uma fatia visualmente mais significativa nas regiões nordeste e sul em comparação aos seus concorrentes diretos, o que pode indicar uma estratégia de expansão logística mais agressiva ou uma base de usuários mais pulverizada fora do Sudeste.

Magazine Luiza online mantém uma distribuição muito equilibrada, o que é coerente com sua estratégia de utilizar lojas físicas como minicentros de distribuição em diversos estados. Americanas e ShopeePay devido ao baixo volume amostral nesta base específica, as variações regionais são menos perceptíveis, não permitindo uma inferência estatística robusta sobre sua performance geográfica.

c. Tratamento da base de dados

Os dados foram extraídos do portal consumidor.org referente ao mês de fevereiro de 2026, submetemos a um processo de estruturação para viabilizar o uso de algoritmos de aprendizagem de máquina.

A base original em formato csv foi carregada e limpa, removendo registros inconsistentes e selecionando as variáveis de interesse (Região, Empresa e Tipo de Problema). Aplicamos a técnica de *Label Encoding*, já que o modelo matemático

não processa dados textuais diretamente. Este método converte categorias qualitativas (ex. Mercado Livre, Sudeste ou Entrega) em valores numéricos discretos, permitindo o processamento matricial pelo algoritmo.

Dividimos a base para garantir a capacidade de generalização do modelo e evitar a decoragem de dados, a base foi dividida utilizando o método holdout, 70% para treino, utilizando os dados para o ajuste dos parâmetros do modelo e 30% para teste, com dados inéditos utilizados para validar a capacidade preditiva do algoritmo.

d. Definição e descrição das bases teóricas dos métodos

Foi utilizado o método *Random forest* de aprendizagem supervisionada, analisando subamostra dos dados e entrega de previsão (ex. resolvida ou não resolvida), onde o resultado que aparece com mais frequência entre todas as árvores é escolhido como previsão oficial. Este método foi escolhido por sua alta resistência a *outliers* e por lidar bem com variáveis categóricas (ex. Regiões e Empresas), oferecendo uma estabilidade superior a uma árvore de decisão comum.

e. Definição e descrição de como será calculada a acurácia

Para medir o desempenho do modelo e entender sua eficácia em prever o desfecho das reclamações, utilizaremos métricas de avaliação de classificação.

A métrica principal será o indicador primário, calculada pela razão entre as previsões corretas e o total de casos testados, total de acertos (positivos + negativos) dividido pelo total de casos na base de teste.

Utilizaremos também a matriz de confusão para indicar o volume de reclamações que o modelo previu como resolvidas e realmente foram, falso positivo que são as reclamações que o modelo previu como resolvidas, mas ficaram sem solução e meta de performance que apresenta uma métrica superior à média de aleatoriedade, servindo como uma ferramenta de apoio à decisão para os e-commerces analisados.

3. Descrição dos Resultados e Modelo de Negócios

A partir da análise realizada nas cinco principais empresas, com a inclusão do código “análise_diagnóstica” no nosso projeto aplicado II, identificamos que o problema central não é apenas a logística, mas a falha na recuperação do cliente.

- Eficiência Preditiva: O modelo *Random Forest* implementado, demonstrou que variáveis como “Tipo de Problema” e “Região” são preditores fortes dos desfechos das reclamações.
- Gargalo Crítico: Foi possível identificar que o Mercado Livre, apesar do volume, possui uma infraestrutura de dados que permite maior rastreabilidade, enquanto empresas como a Amazon enfrentam desafios específicos de malha logística que impactam diretamente a nota de satisfação.

3.1. Definição do Produto.

O produto deste projeto é uma plataforma de suporte à decisão B2B.

- Qual produto? Um Dashboard dinâmico integrado a um modelo preditivo.
- Funcionalidade Principal: O sistema recebe os dados de uma reclamação em tempo real e analisa/calcula a probabilidade de ela não ser resolvida.
- Diferencial: Permite que a empresa priorize o atendimento de casos com alto risco de reincidência ou de danos à imagem da marca.

3.2. Modelo de Negócios.

Buscando uma coerência no projeto, propomos o seguinte modelo:

- Proposta de Valor: Redução da perda de clientes e otimização dos custos operacionais do SAC através da priorização inteligente baseada em IA.
- Possíveis Clientes: Grandes e-commerces (como os analisados) e empresas de logística que buscam transparência e regulação.
- Receita: Assinatura mensal baseada no volume de dados processados (API de predição).
- Canais: Integração direta via API com sistemas de CRM e portais como o consumidor.gov.

4. Link github

<https://github.com/V-code7/Projeto-aplicado-2.git>